

Projet Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Projet : E-commerce de Cadeaux

Préparé par Haythem FRIKHA

Année Universitaire : 2025-2026

Table des matières

1	Introduction	3
1.1	Architecture du Projet	3
1.1.1	Structure des Répertoires	3
2	Prétraitement des Données	3
2.1	Gestion des Valeurs Manquantes	3
2.1.1	Variable Age	4
2.1.2	Variable AvgDaysBetweenPurchases	4
2.2	Traitement des Valeurs Aberrantes	4
2.3	Ingénierie des Variables	4
2.3.1	Date d'inscription	4
2.3.2	Adresse IP	4
2.4	Suppression des Variables Non Fiables	5
3	Détection et Correction des Fuites de Données	5
3.1	Variables Exclues	5
3.2	Analyse de la Variable Recency	5
4	Modélisation Prédictive du Churn	5
4.1	Préparation des Données pour la Modélisation	5
4.1.1	Encodage des Variables	6
4.1.2	Séparation Train/Test	6
4.1.3	Gestion du Déséquilibre de Classes	6
4.2	Modèles Évalués	6
4.3	Optimisation des Hyperparamètres	6
4.4	Importance des Variables	7
5	Segmentation Client	7
5.1	Méthodologie	7
5.1.1	Variables RFM	7
5.1.2	Algorithme de Clustering	7
5.2	Segments Identifiés	7
5.3	Recommandations Marketing par Segment	8
6	Visualisations Générées	8
6.1	Comparaison des Modèles	8
6.2	Courbes ROC	9
6.3	Matrice de Confusion	9
6.4	Importance des Variables	9
6.5	Distribution des Segments	10
6.6	Heatmap des Profils RFM	10
7	Déploiement de l'Interface Flask	11
7.1	Objectif du Déploiement	11
7.2	Structure Applicative Mise en Place	11
7.3	Fonctionnalités Réalisées	11
7.3.1	Prédiction d'un Client	11
7.3.2	Traitement Batch avec Pagination Contrôlée	12

7.3.3	Endpoints API Opérationnels	12
7.4	Ajustements de l'Interface Utilisateur	12
8	Conclusion	12
8.1	Perspectives	12

1 Introduction

Ce rapport présente les travaux réalisés dans le cadre de l'atelier Machine Learning portant sur l'analyse comportementale de la clientèle d'une boutique e-commerce spécialisée dans les cadeaux. L'objectif principal de ce projet est de développer des solutions d'apprentissage automatique permettant de :

- **Personnaliser la stratégie marketing** grâce à la segmentation client
- **Réduire le taux d'attrition** (churn) par la modélisation prédictive
- **Augmenter le chiffre d'affaires** en ciblant les clients à risque

Le jeu de données mis à disposition contient **4 372 clients** décrits par **52 variables**, incluant des métriques RFM (Récence, Fréquence, Montant), des données démographiques, des comportements d'achat et des informations de compte.

1.1 Architecture du Projet

Une architecture logicielle bien organisée est essentielle pour la maintenabilité, la reproductibilité et le déploiement des solutions de Machine Learning. Cette sous-section détaille la structure des répertoires du projet.

1.1.1 Structure des Répertoires

Le projet suit une organisation standard pour les projets de science des données, séparant clairement les données brutes, les données traitées, le code, les modèles et les résultats.

```
1 ml-retail/
2 |-- data/
3 |   |-- raw/                # Donnees brutes
4 |   |-- processed/         # Donnees nettoyees
5 |   |-- train_test/        # Ensembles train/test
6 |-- models/               # Modeles entraines
7 |-- reports/              # Visualisations
8 |-- src/                  # Code source
9 |   |-- preprocessing.py   # Pipeline de pretraitement
10 |   |-- train_model.py    # Entrainement des modeles
11 |   |-- segmentation.py   # Segmentation client
12 |   |-- predict.py        # Script de prediction
13 |   |-- utils.py          # Fonctions utilitaires
```

2 Prétraitement des Données

Le prétraitement constitue une étape cruciale pour garantir la qualité des modèles. Nous avons implémenté un pipeline complet dans le fichier `src/preprocessing.py`.

2.1 Gestion des Valeurs Manquantes

Plusieurs stratégies ont été mises en place pour traiter les valeurs manquantes selon la nature de chaque variable.

2.1.1 Variable Age

La variable **Age** présentait **1 311 valeurs manquantes** (29,99% du dataset). Nous avons opté pour une imputation par la méthode des **K plus proches voisins (KNN)** avec les paramètres suivants :

- Nombre de voisins : $k = 5$
- Pondération par la distance inverse
- Variables utilisées : Recency, Frequency, MonetaryTotal, MonetaryAvg, CustomerTenureDays, FirstPurchaseDaysAgo

Cette approche permet de prendre en compte les corrélations entre l'âge et les comportements d'achat, offrant une imputation plus réaliste qu'une simple moyenne ou médiane.

2.1.2 Variable AvgDaysBetweenPurchases

Cette variable contenait **79 valeurs manquantes**, imputées par la médiane (1,15 jours).

2.2 Traitement des Valeurs Aberrantes

Certaines variables contenaient des **valeurs sentinelles** utilisées pour encoder des données manquantes ou des erreurs :

Variable	Valeurs aberrantes	Nombre d'occurrences
SupportTicketsCount	-1, 999	130 (2,97%)
SatisfactionScore	-1, 0, 99	349 (7,98%)

TABLE 1 – Valeurs sentinelles identifiées et corrigées

Ces valeurs ont été remplacées par la médiane de chaque variable respective, puis bornées aux plages valides (0-15 pour SupportTicketsCount, 1-5 pour SatisfactionScore).

2.3 Ingénierie des Variables

Afin d'améliorer la capacité prédictive du modèle, nous avons créé de nouvelles variables à partir des données brutes.

2.3.1 Date d'inscription

La variable **RegistrationDate** a été parsée et décomposée en quatre nouvelles variables :

- **RegYear** : Année d'inscription
- **RegMonth** : Mois d'inscription
- **RegDay** : Jour d'inscription
- **RegWeekday** : Jour de la semaine (0=Lundi, 6=Dimanche)

2.3.2 Adresse IP

À partir de la variable **LastLoginIP**, nous avons extrait :

- **IsPrivateIP** : Indicateur booléen (326 clients avec IP privée)
- **LoginCountry** : Pays de connexion (via la base DB-IP Lite)

La distribution des pays de connexion révèle une clientèle majoritairement américaine (1 494 clients), suivie de la Chine (362) et du Japon (219).

2.4 Suppression des Variables Non Fiabiles

Certaines variables ont dû être exclues du preprocessing en raison de leur fiabilité douteuse.

La variable `NewsletterSubscribed` a été supprimée car identifiée comme non fiable dans la documentation du projet.

3 Détection et Correction des Fuites de Données

Une analyse approfondie des corrélations entre les variables et la cible **Churn** a révélé plusieurs cas de **fuite de données** (data leakage) compromettant la validité des modèles.

3.1 Variables Exclues

Le tableau suivant récapitule les variables supprimées et les raisons de leur exclusion.

Variable	Raison de l'exclusion
ChurnRiskCategory	Directement dérivée de la variable cible (100% de corrélation)
RFMSegment	La catégorie "Dormants" correspond à 100% de clients churned
CustomerType	La catégorie "Perdu" correspond à 100% de clients churned
Recency	Séparation parfaite : Churn=0 si Recency $\leq$ 90 jours, Churn=1 si Recency > 90 jours

TABLE 2 – Variables exclues pour cause de fuite de données

3.2 Analyse de la Variable Recency

L'analyse a montré que la variable **Recency** définit elle-même le churn :

- Clients non churned : Recency $\in [1, 90]$ jours
- Clients churned : Recency $\in [91, 374]$ jours

Cette découverte est critique car elle indique que le churn est défini comme l'inactivité supérieure à 90 jours. Utiliser cette variable reviendrait à prédire le passé avec le passé.

4 Modélisation Prédicative du Churn

Cette section détaille le processus de construction et d'évaluation de modèles de classification pour prédire le churn client. Plusieurs approches ont été mises en place, du prétraitement des données à la comparaison de sept algorithmes différents.

4.1 Préparation des Données pour la Modélisation

Avant d'entraîner les modèles, nous avons effectué plusieurs transformations essentielles sur les données.

4.1.1 Encodage des Variables

- **Variables numériques (35)** : Standardisation avec `StandardScaler`
- **Variables catégorielles (14)** : Encodage one-hot avec `OneHotEncoder`

4.1.2 Séparation Train/Test

Le dataset a été divisé en :

- **Ensemble d'entraînement** : 3 497 échantillons (80%)
- **Ensemble de test** : 875 échantillons (20%)

La stratification a été appliquée pour maintenir la distribution de la variable cible (33,26% de churn) dans les deux ensembles.

4.1.3 Gestion du Déséquilibre de Classes

Le taux de churn de 33,26% représente un déséquilibre modéré. Nous avons appliqué la technique **SMOTE** (Synthetic Minority Over-sampling Technique) sur l'ensemble d'entraînement :

- Avant SMOTE : 2 334 non-churned, 1 163 churned
- Après SMOTE : 2 334 non-churned, 2 334 churned

4.2 Modèles Évalués

Sept algorithmes de classification ont été entraînés et comparés :

Modèle	Accuracy	Precision	Recall	F1	ROC-AUC
XGBoost (Tuned)	99,1%	99,0%	98,3%	98,6%	99,97%
Logistic Regression	98,4%	98,6%	96,6%	97,6%	99,8%
Gradient Boosting	98,3%	96,9%	97,9%	97,4%	99,9%
Decision Tree	97,3%	94,9%	96,9%	95,9%	97,2%
SVM	97,1%	98,9%	92,4%	95,6%	99,7%
Random Forest	94,9%	96,6%	87,6%	91,9%	98,7%
KNN	84,1%	70,9%	88,7%	78,8%	92,5%

TABLE 3 – Comparaison des performances des modèles sur l'ensemble de test

4.3 Optimisation des Hyperparamètres

Afin d'améliorer encore les performances du modèle le plus prometteur, le modèle XGBoost, identifié comme le plus performant selon le score F1, a fait l'objet d'une optimisation par **GridSearchCV** avec validation croisée à 5 plis.

Hyperparamètres optimaux - XGBoost

- `learning_rate` : 0,1
- `max_depth` : 7
- `n_estimators` : 100
- `subsample` : 0,8

Score F1 en validation croisée : 99,09%

4.4 Importance des Variables

Comprendre quels facteurs influencent le plus les prédictions du modèle est essentiel pour l'interprétabilité et l'actionabilité. L'analyse de l'importance des variables du modèle XGBoost révèle les facteurs les plus prédictifs du churn :

1. **LoyaltyLevel_Établi** (35,3%) : Les clients établis sont significativement moins susceptibles de cherner
2. **FavoriteSeason_Hiver** (20,4%) : Les habitudes d'achat saisonnières sont fortement prédictives
3. **PreferredMonth** (20,0%) : Le mois d'achat préféré indique le niveau d'engagement
4. **LoyaltyLevel_Nouveau** (5,8%) : Les nouveaux clients présentent des patterns distincts
5. **CustomerTenureDays** (4,5%) : L'ancienneté du client

5 Segmentation Client

En complément de la prédiction du churn, une approche complémentaire basée sur la segmentation client a été développée. Cette analyse RFM permet de personnaliser les stratégies marketing et d'identifier les groupes de clients ayant des besoins et des caractéristiques distincts.

5.1 Méthodologie

La segmentation a été réalisée en utilisant une approche quantitative fondée sur l'algorithme K-Means.

5.1.1 Variables RFM

- **Recency** : Nombre de jours depuis le dernier achat
- **Frequency** : Nombre total d'achats
- **Monetary** : Montant total dépensé

5.1.2 Algorithme de Clustering

Nous avons utilisé l'algorithme **K-Means** avec les étapes suivantes :

1. Standardisation des variables RFM avec **StandardScaler**
2. Recherche du nombre optimal de clusters via le score de silhouette
3. Application de K-Means avec $k = 3$ clusters

5.2 Segments Identifiés

L'application de l'algorithme K-Means a révélé trois segments distincts avec des profils RFM et des taux de churn très différents.

Segment	Clients	Taux Churn	Récence moy.	Fréq. moy.	Montant moy.
À Risque	1 109 (25,4%)	100%	246 jours	1,85	460 \$
Champions	26 (0,6%)	0%	6 jours	83,35	75 966 \$
Clients Actifs	3 237 (74,0%)	11%	40 jours	5,55	1 796 \$

TABLE 4 – Profil des segments clients identifiés

5.3 Recommandations Marketing par Segment

Pour maximiser l'efficacité des interventions marketing, des recommandations spécifiques ont été élaborées pour chaque segment.

Segment Champions (Priorité : HAUTE VALEUR)

Actions recommandées :

- Offres exclusives et accès anticipé aux nouveaux produits
- Programme de fidélité avec avantages VIP
- Sollicitation d'avis et programme de parrainage
- Communications personnalisées de remerciement

Canaux : Email, Courrier direct, Gestionnaire de compte dédié

Segment À Risque (Priorité : URGENTE)

Actions recommandées :

- Campagne de reconquête avec remises spéciales
- Enquête pour comprendre les raisons de l'inactivité
- Messages personnalisés "Vous nous manquez"
- Offres exclusives à durée limitée

Canaux : Email, SMS, Courrier direct

Segment Clients Actifs (Priorité : MOYENNE)

Actions recommandées :

- Up-selling vers des produits de valeur supérieure
- Cross-selling de produits complémentaires
- Seuils de livraison gratuite pour augmenter le panier moyen
- Accès anticipé aux soldes

Canaux : Email, Publicités de retargeting

6 Visualisations Générées

Le projet génère six visualisations clés stockées dans le répertoire `reports/`. Chaque graphique fournit des insights critiques pour comprendre la performance du modèle et le comportement client, couvrant la comparaison des modèles, l'évaluation prédictive et l'analyse des segments.

6.1 Comparaison des Modèles

Cette visualisation présente deux graphiques en barres côte à côte permettant une comparaison rapide des sept algorithmes :

- **Panneau gauche :** Métriques de classification (Accuracy, Precision, Recall, F1) pour chaque modèle
- **Panneau droit :** Score ROC-AUC par modèle

Elle permet d'identifier rapidement XGBoost comme le modèle le plus performant sur tous les critères.




FIGURE 1 – Comparaison visuelle des performances des 7 modèles (métriques de classification et ROC-AUC).

6.2 Courbes ROC

Au-delà des métriques de base, une analyse plus fine de la capacité discriminante des modèles est nécessaire. Les courbes ROC affichent les performances de tous les modèles sur un même graphique :

- Axe X : Taux de faux positifs (FPR)
- Axe Y : Taux de vrais positifs (TPR)
- La ligne diagonale représente un classifieur aléatoire ($AUC = 0,5$)

Les courbes proches du coin supérieur gauche indiquent une meilleure performance.

6.3 Matrice de Confusion

Pour une compréhension granulaire des erreurs de classification du meilleur modèle, une matrice de confusion détaillée est générée. Elle présente les résultats de prédiction du modèle XGBoost sous forme de heatmap :

- **Vrais Négatifs (TN)** : Clients correctement identifiés comme non-churned
- **Vrais Positifs (TP)** : Clients correctement identifiés comme churned
- **Faux Positifs (FP)** : Clients non-churned incorrectement classés (erreur de Type I)
- **Faux Négatifs (FN)** : Clients churned manqués (erreur de Type II)

6.4 Importance des Variables

Pour comprendre les drivers du churn, une analyse de l'importance des variables est essentielle. Le graphique en barres horizontales affiche les 20 variables les plus influentes du modèle XGBoost, classées par leur contribution à la réduction des erreurs de prédiction.




FIGURE 2 – Top des variables les plus contributives dans le modèle XGBoost.

6.5 Distribution des Segments

À l'inverse des métriques de classification, cette visualisation se concentre sur les patterns comportementaux identifiés par la segmentation. Elle présente les résultats du clustering sous deux angles :

- **Diagramme circulaire** : Répartition des clients par segment
- **Diagramme en barres** : Taux de churn par segment




FIGURE 3 – Distribution des clients par segment et comparaison des taux de churn associés.

6.6 Heatmap des Profils RFM

Pour synthétiser les caractéristiques distinctives de chaque segment, une heatmap normalisée offre une vue d'ensemble des profils RFM. Elle présente une matrice colorée montrant les profils

RFM normalisés de chaque segment :

- Lignes : Métriques RFM (Récence, Fréquence, Montant)
- Colonnes : Segments clients
- Valeurs : Scores normalisés entre 0 et 1

7 Déploiement de l'Interface Flask

Pour finaliser la phase de déploiement du projet, nous avons implémenté une interface basée sur Flask qui met en production le modèle de churn et les résultats de segmentation.

7.1 Objectif du Déploiement

L'objectif de cette interface est de transformer le pipeline analytique en application utilisable, afin de permettre à un utilisateur de :

- Prédire le churn pour un client donné
- Lancer un scoring en mode batch à partir du jeu de données traité
- Interpréter les résultats via le niveau de risque, le segment assigné et les actions marketing recommandées

7.2 Structure Applicative Mise en Place

La couche de déploiement a été organisée dans le package `src/app/` :

- `web.py` : routes Flask et gestion des requêtes
- `services.py` : chargement des modèles, logique d'inférence, enrichissement par segmentation et calcul des résumés
- `templates/` : gabarits HTML (`base.html`, `index.html`)
- `static/style.css` : style de l'interface

Cette organisation sépare la présentation, le routage et la logique métier, ce qui améliore la maintenabilité.

7.3 Fonctionnalités Réalisées

7.3.1 Prédiction d'un Client

L'interface accepte un `CustomerID`, récupère l'enregistrement correspondant dans le dataset traité, puis affiche :

- La probabilité de churn et la décision finale
- Le niveau de risque (Low, Medium, High, Critical)
- Le segment inféré à partir des variables RFM
- Les recommandations marketing et canaux associés au segment

7.3.2 Traitement Batch avec Pagination Contrôlée

Le workflow *Process all customers* a été optimisé pour la réactivité :

- Seuls les 100 premiers clients de `data/processed/retail_customers_cleaned.csv` sont scorés
- Les résultats sont triés par priorité de churn croissante : Low → Medium → High → Critical
- Une pagination de 10 lignes par page est appliquée avec navigation précédent/suivant

7.3.3 Endpoints API Opérationnels

En complément de l'interface web, des endpoints légers ont été exposés :

- `/health` : vérification de l'état du service
- `/api/summary` : résumé du modèle et du dataset
- `/api/predict` : endpoint de prédiction au format JSON

7.4 Ajustements de l'Interface Utilisateur

Pour obtenir un rendu plus professionnel, l'interface a été ajustée avec :

- Suppression de l'en-tête pour une mise en page plus claire
- Palette de couleurs neutres (gris) en remplacement de l'accent bleu initial
- Style visuel carré/bloc (sans coins arrondis)

Ces améliorations renforcent la lisibilité et la cohérence visuelle pour la démonstration du projet.

8 Conclusion

Ce projet a permis de développer une solution complète d'analyse comportementale client comprenant :

1. **Un pipeline de prétraitement robuste** gérant les valeurs manquantes (KNN pour l'âge), les valeurs aberrantes (valeurs sentinelles) et l'ingénierie de variables (extraction de features temporelles et géographiques).
2. **Une détection rigoureuse des fuites de données** ayant conduit à l'exclusion de 4 variables (ChurnRiskCategory, RFMSegment, CustomerType, Recency) qui auraient artificiellement gonflé les performances.
3. **Un modèle de prédiction du churn performant** (XGBoost) atteignant un score F1 de 98,6% et un ROC-AUC de 99,97% sur l'ensemble de test.
4. **Une segmentation client actionnable** identifiant trois segments distincts avec des recommandations marketing personnalisées.

8.1 Perspectives

Plusieurs pistes d'amélioration peuvent être envisagées :

- Intégration de données temporelles pour une analyse de séries chronologiques
- Développement d'un tableau de bord interactif pour le suivi en temps réel
- Mise en production du modèle via une API REST
- A/B testing des recommandations marketing par segment